LAPORAN EVALUASI AKHIR PEMODELAN SENTIMEN

Penelitian: Sentimen Penetapan Bencana Nasional **Tahap:** Modeling Part20 — Final Evaluation Report **Konfigurasi CV:** SGKF_3fold_seed123 **Tanggal laporan (UTC):** 2026-10-18T14:22:08.939790+00:00

Laporan ini disusun menggunakan artefak OOF yang telah dikunci dari Part12, Part18, dan Part19. Tidak dilakukan pelatihan model baru atau pengubahan data.

1. Metodologi Evaluasi

Penelitian ini mengevaluasi 348 tweet yang dikelompokkan menjadi 337 leakage group. Data terdiri atas tiga kasus, yaitu Lombok 2018 (101 tweet), Palu 2018 (105 tweet), dan Sumatera 2025 (142 tweet).

Evaluasi menggunakan Stratified Group K-Fold sebanyak tiga fold, dengan seed 123. Setiap fold terdiri atas 232 tweet training dan 116 tweet validation.

Dua model dibandingkan pada keanggotaan validation fold yang identik, yaitu TF-IDF dengan Logistic Regression sebagai baseline dan LSTM_SMALL_V1.

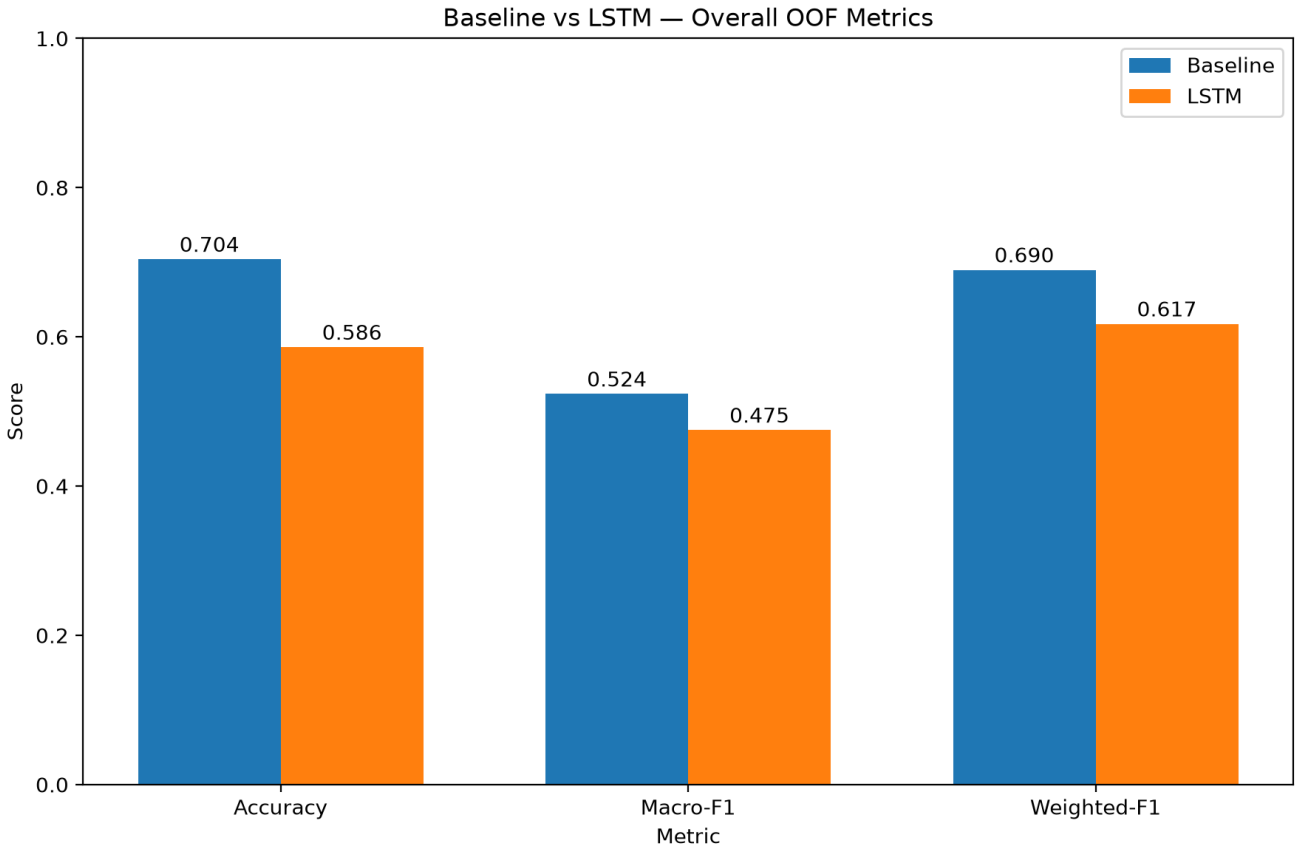
Metrik utama penelitian adalah OOF Macro-F1, sedangkan accuracy, precision, recall, dan weighted-F1 menjadi metrik pendukung.

2. Hasil Evaluasi Keseluruhan

model	accuracy	macro_precision	macro_recall	macro_f1	weighted_f1
baseline	0.7040	0.7761	0.4943	0.5236	0.6898
lstm	0.5862	0.4760	0.5596	0.4751	0.6175

Baseline memperoleh accuracy 70.40% dan Macro-F1 0.5236, sedangkan LSTM mencapai accuracy 58.62% dan Macro-F1 0.4751.

Selisih Macro-F1 LSTM terhadap baseline adalah -0.0484. Baseline memiliki performa agregat yang lebih baik menurut accuracy dan Macro-F1, sedangkan LSTM memiliki Macro-Recall yang lebih tinggi.



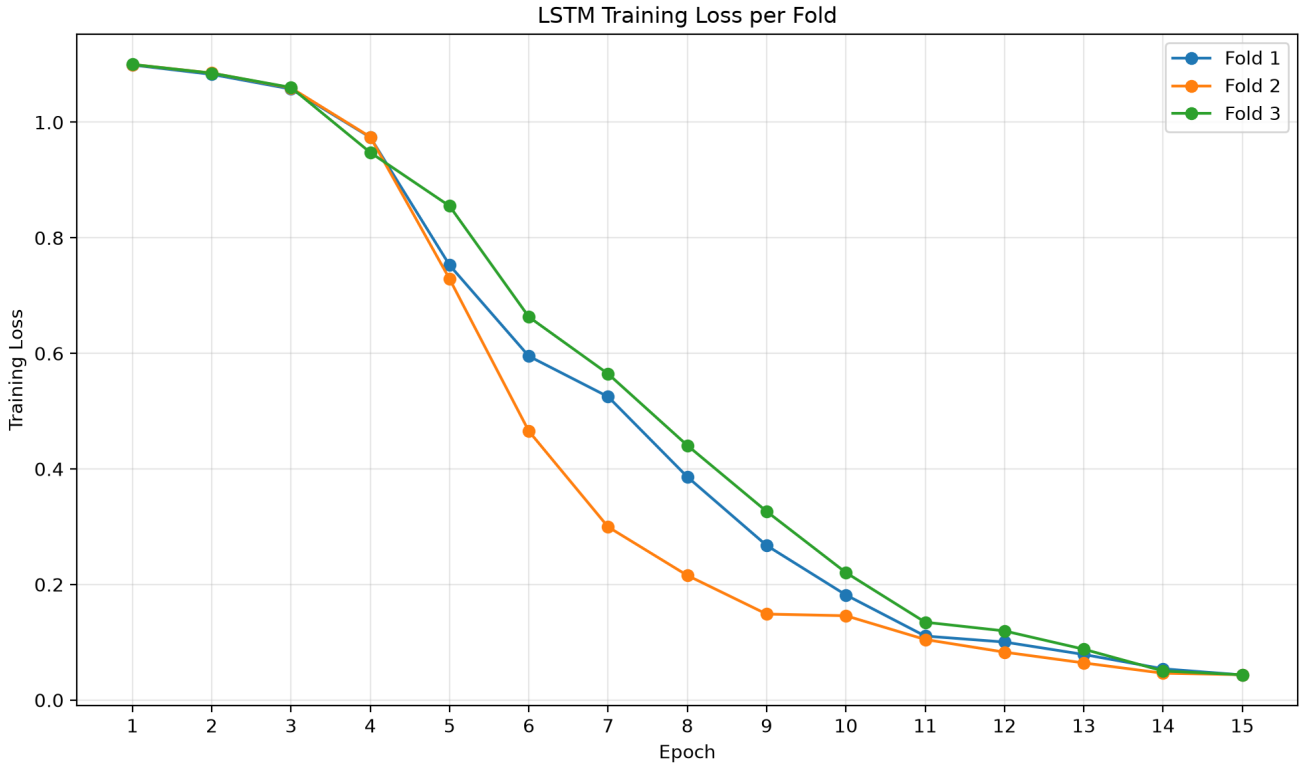
Gambar 1. Perbandingan metrik OOF baseline dan LSTM.

3. Analisis Training LSTM

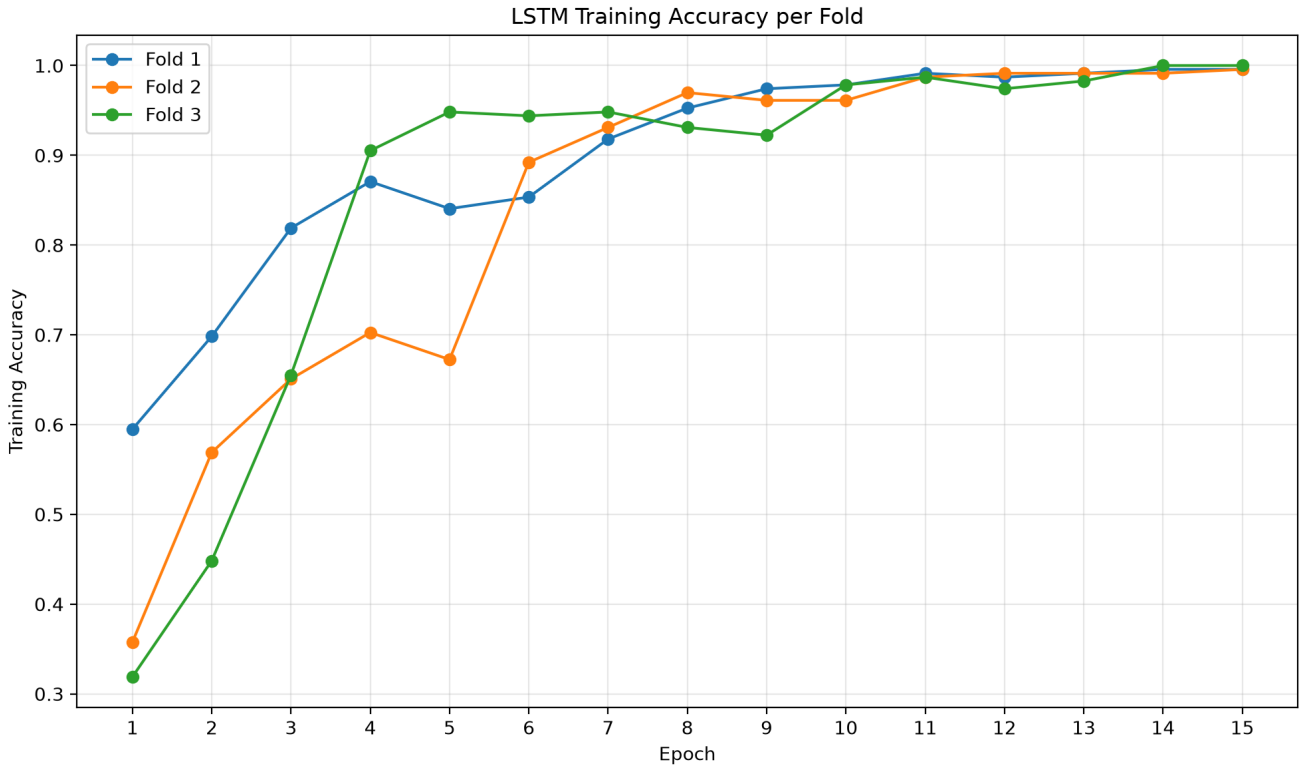
LSTM menggunakan arsitektur Embedding 32 dimensi, LSTM 32 unit, dropout 0,30 dan softmax tiga kelas, dengan total 168.419 parameter. Model dilatih 15 epoch pada masing-masing fold.

Akurasi training akhir berturut-turut: 99.57%, 99.57%, 100.00%. Loss training akhir berturut-turut: 0.0435, 0.0438, 0.0437.

Sebaliknya, accuracy OOF per fold LSTM berada sekitar 55%–62%. Perbedaan antara training dan validation mengindikasikan overfitting. Karena validation tidak dipakai selama fit(), laporan ini tidak menyatakan epoch optimal atau validation-loss trajectory.



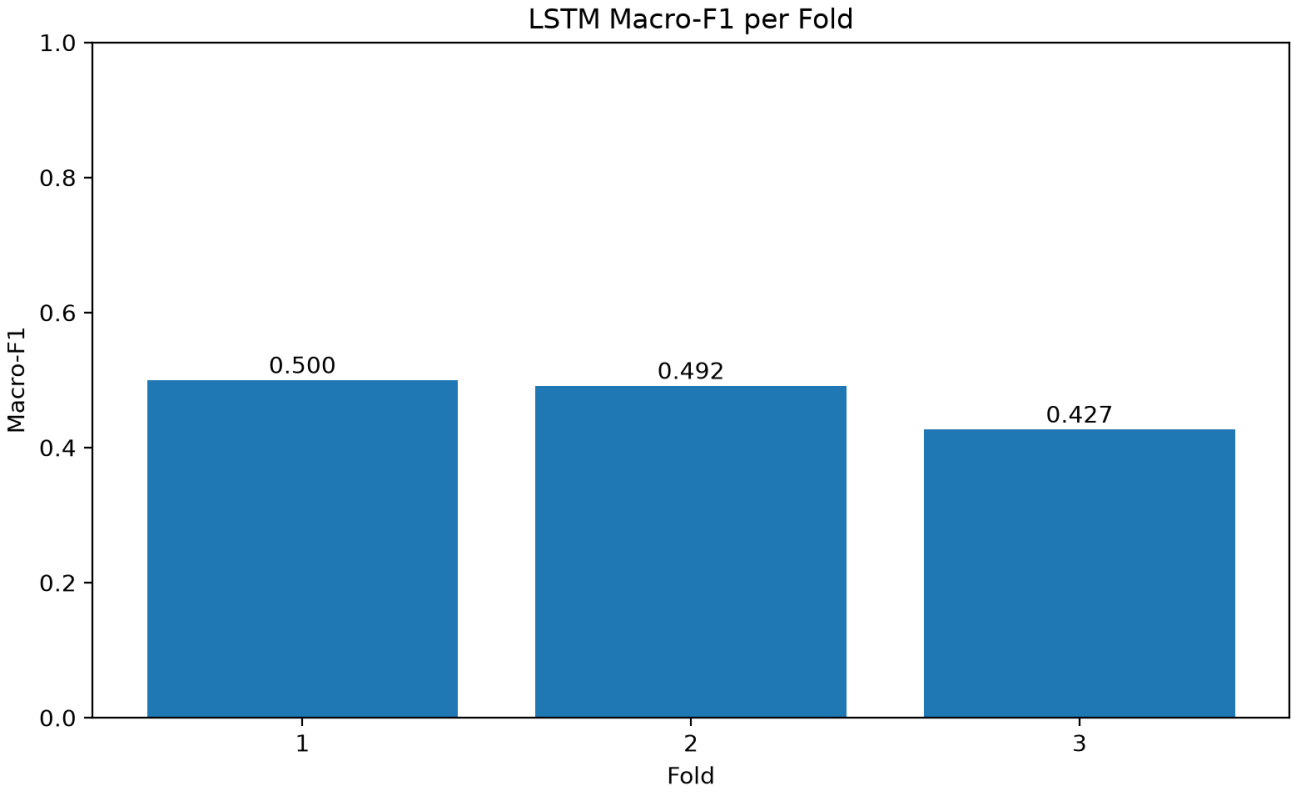
Gambar 2. Perubahan training loss pada tiga fold.



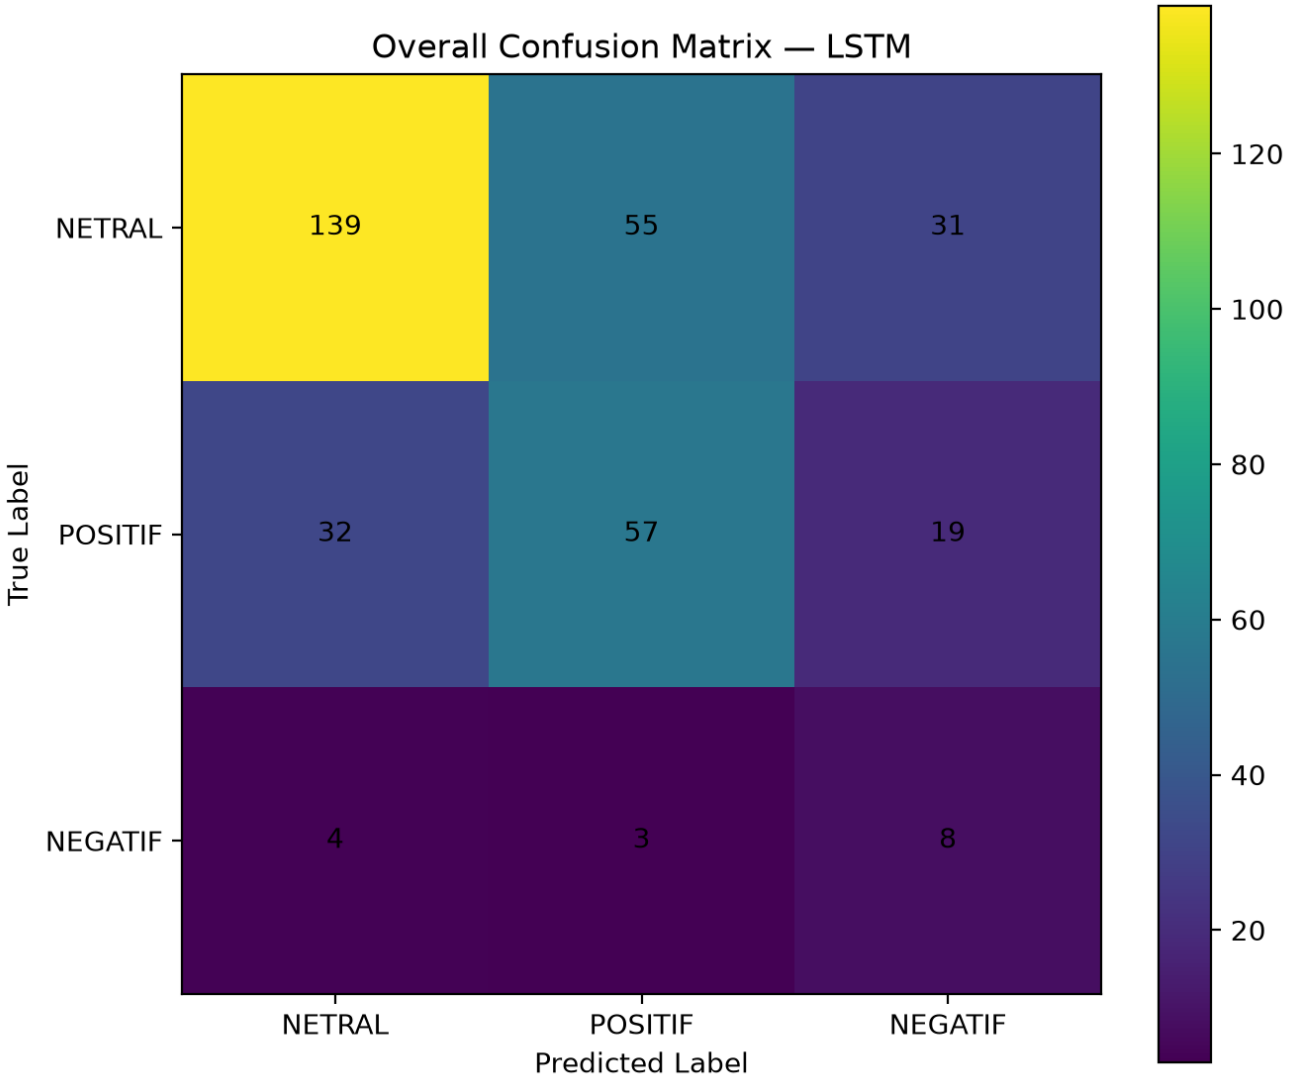
Gambar 3. Perubahan training accuracy pada tiga fold.

4. Evaluasi Macro-F1 dan Confusion Matrix LSTM

OOF Macro-F1 LSTM secara keseluruhan adalah 0.4751. Rata-rata nilai Macro-F1 ketiga validation fold dapat berbeda sedikit dari Macro-F1 agregat OOF karena prosedur agregasi metriknya berbeda.



Gambar 4. Macro-F1 LSTM per fold.

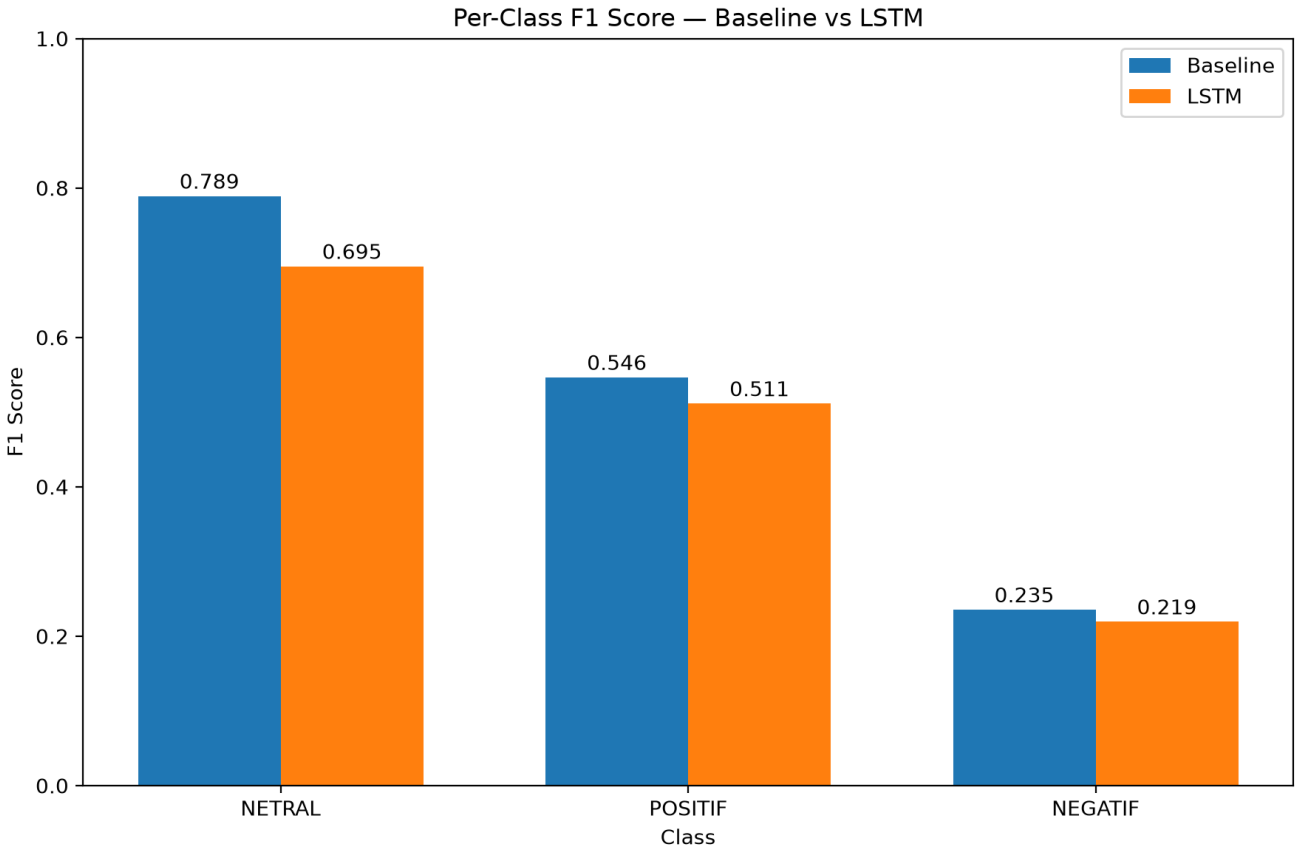


Gambar 5. Confusion matrix agregat OOF model LSTM.

Dari 348 tweet, LSTM mengklasifikasikan 204 tweet secara benar dan 144 tweet secara salah.

5. Perbandingan Per Kelas

model	label	precision	recall	f1	support
baseline	NETRAL	0.7510	0.8311	0.7890	225
baseline	POSITIF	0.5773	0.5185	0.5463	108
baseline	NEGATIF	1.0000	0.1333	0.2353	15
lstm	NETRAL	0.7943	0.6178	0.6950	225
lstm	POSITIF	0.4957	0.5278	0.5112	108
lstm	NEGATIF	0.1379	0.5333	0.2192	15



Gambar 6. Perbandingan F1-score setiap kelas sentimen.

Kelas NEGATIF berjumlah 15 tweet. Baseline mengenali 2 tweet NEGATIF secara benar, sedangkan LSTM mengenali 8 tweet secara benar.

Namun, LSTM juga membuat 50 prediksi NEGATIF yang sebenarnya berasal dari kelas lain. Hal tersebut menyebabkan precision NEGATIF LSTM hanya 13.79% walaupun recall mencapai 53.33%.

6. Perbandingan Berdasarkan Kasus Bencana

model	case	rows	accuracy	macro_f1	weighted_f1
baseline	lombok_2018	101	0.7030	0.4406	0.6844
baseline	palu_2018	105	0.6952	0.5481	0.6891
baseline	sumatra_2025	142	0.7113	0.5377	0.6936
lstm	lombok_2018	101	0.6139	0.4627	0.6325
lstm	palu_2018	105	0.7048	0.5889	0.7165
lstm	sumatra_2025	142	0.4789	0.4105	0.5248

LSTM memiliki Macro-F1 lebih tinggi daripada baseline pada kasus Lombok 2018 dan Palu 2018, tetapi lebih rendah pada Sumatera 2025. Perbedaan ini merupakan temuan deskriptif dan belum membuktikan penyebab perbedaan karakteristik tiap kasus.

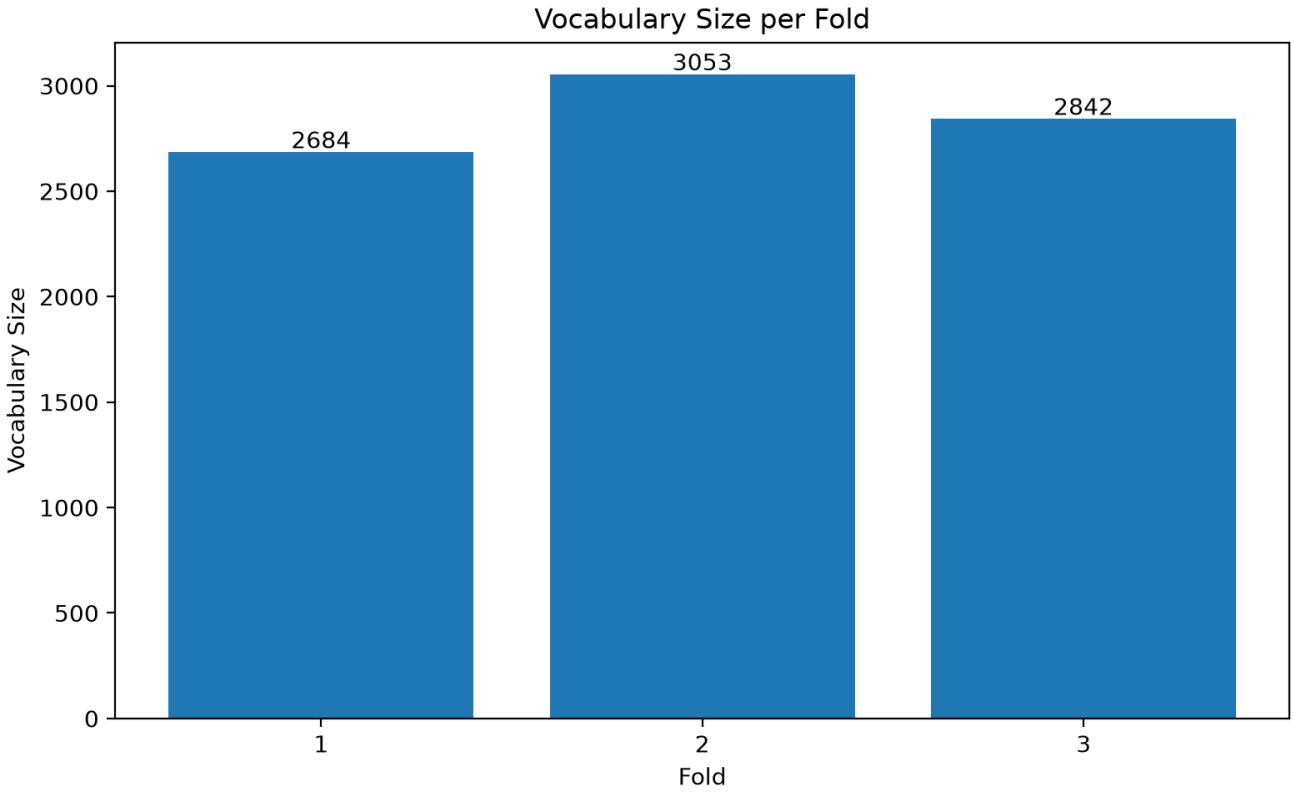
7. Analisis Kesalahan Berpasangan

category	count	percentage
both_correct	165	47.41%
baseline_only_correct	80	22.99%
lstm_only_correct	39	11.21%
both_wrong	64	18.39%

Kedua model benar pada 165 tweet. Baseline saja benar pada 80 tweet, sedangkan LSTM saja benar pada 39 tweet.

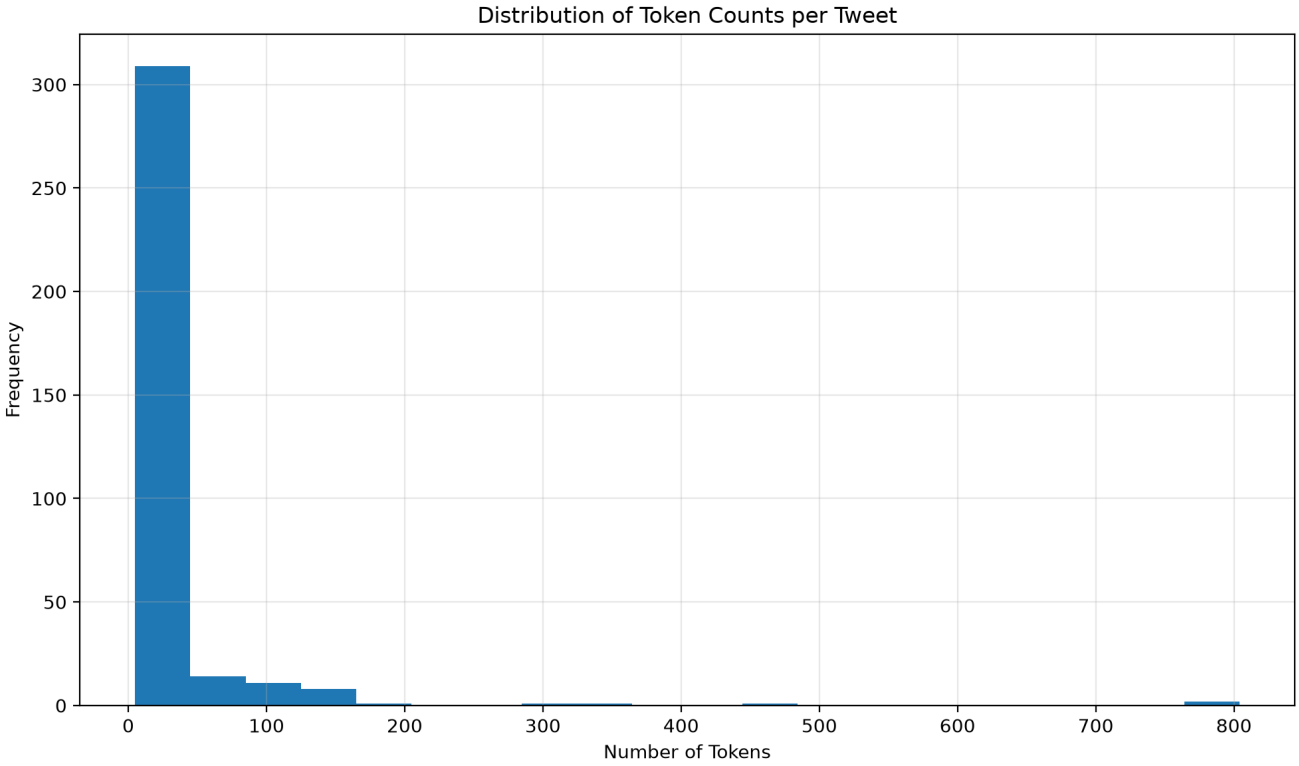
Kedua model sama-sama salah pada 64 tweet. Temuan ini menunjukkan bahwa kedua model memiliki sebagian pola kesalahan yang berbeda, tetapi tidak membuktikan bahwa kombinasi keduanya akan meningkatkan performa.

8. Karakteristik Token dan Vocabulary



Gambar 7. Ukuran vocabulary training-only per fold.

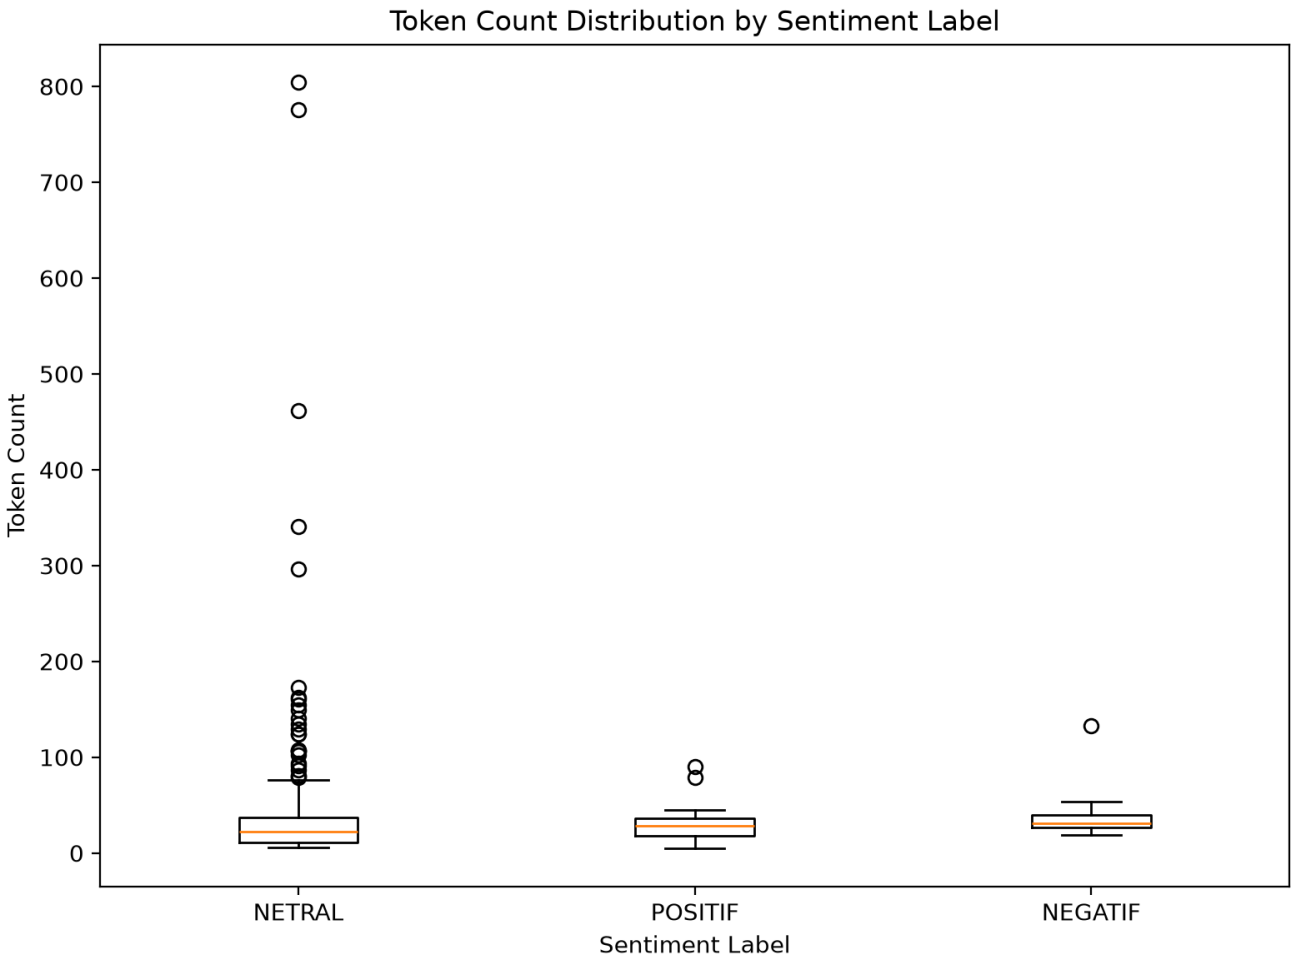
Vocabulary LSTM berturut-turut berisi 2.684, 3.053, dan 2.842 entri, berada di bawah batas maksimum 5.000. Tokenizer dibentuk dari training fold masing-masing untuk mencegah kebocoran vocabulary dari validation.



Gambar 8. Distribusi jumlah token per tweet.

Statistik panjang teks setelah preprocessing (dihitung dengan pemisahan whitespace): minimum 5, median 26.0, rata-rata 37.72, dan maksimum 804 token.

Sebanyak 14 dari 348 tweet memiliki lebih dari 128 token sebelum vectorization. Perhitungan ini bersifat deskriptif pada teks akhir, bukan penghitungan indeks vocabulary aktif.



Gambar 9. Distribusi panjang teks menurut sentimen.

Boxplot membantu membandingkan panjang teks NETRAL, POSITIF, dan NEGATIF. Perbedaan panjang teks tidak dengan sendirinya membuktikan adanya pengaruh kausal terhadap akurasi klasifikasi.

9. Keterbatasan Penelitian

1. **Ukuran dataset.** Evaluasi dilakukan terhadap 348 tweet sehingga hasil belum dapat digeneralisasi untuk populasi diskusi media sosial yang lebih luas.

2. **Ketidakseimbangan kelas.** Distribusi sentimen adalah NETRAL 225, POSITIF 108, dan NEGATIF 15. Kelas NEGATIF hanya memiliki 5 validation tweet pada setiap fold.

3. **Tidak tersedia independent holdout test set.** Hasil dilaporkan sebagai out-of-fold evaluation, bukan estimasi kinerja pada sampel independen.

4. **Overfitting LSTM.** Training accuracy sangat tinggi, tetapi kinerja validation lebih rendah.

5. **Cakupan topik.** Dataset berasal dari tiga peristiwa bencana dengan periode dan konteks berbeda sehingga hasil bisa dipengaruhi karakteristik pembicaraan tiap peristiwa.

6. **Perbandingan bersifat deskriptif.** Tidak dilakukan klaim signifikansi statistik, kausalitas, atau keunggulan di luar konfigurasi yang diuji.

7. **Potensi bias pengumpulan dan anotasi data.** Distribusi tweet yang terkumpul dan proses penentuan label dapat memengaruhi hasil; evaluasi ini tidak membuktikan sampel representatif terhadap seluruh opini publik.

10. Kesimpulan Pemodelan

Pada dataset dan protokol evaluasi yang digunakan, model TF-IDF + Logistic Regression memiliki kinerja agregat lebih baik daripada LSTM_SMALL_V1 berdasarkan accuracy dan OOF Macro-F1.

LSTM menghasilkan recall lebih tinggi pada kelas NEGATIF, tetapi disertai banyak false positive. Dengan demikian, penelitian ini memperlihatkan trade-off antara sensitivitas kelas minoritas dan precision klasifikasinya.

Model baseline menjadi hasil terbaik di antara dua konfigurasi yang dievaluasi menurut metrik utama OOF Macro-F1. Kesimpulan tersebut dibatasi pada dataset, skema cross-validation, dan parameter yang telah ditetapkan sebelumnya.

11. Provenance

• Baseline: Modeling Part12

• LSTM training: Modeling Part18

• Comparative evaluation: Modeling Part19

• Visualisasi: commit a613f00992acf1bc6e4a4f34240bc0a4d13a8139

• Final report: Modeling Part20

• Training ulang: tidak dilakukan